

10. User Personas y Casos de Uso

Para diseñar un producto que sirva a usuarios de 20 a 60 años, necesitamos entender quiénes son, qué necesitan y cómo se comportan. Este capítulo define cuatro user personas representativas del rango objetivo, con casos de uso concretos que Koru debe resolver.

10.1 Persona 1: Martín, 26, Desarrollador Junior

Martín vive en Buenos Aires, trabaja como desarrollador junior en una startup y gana el equivalente a USD 1.200/mes. Es digital native, usa Notion para notas, Google Calendar para reuniones y Splitwise para dividir gastos con sus roommates. Tiene ChatGPT instalado pero solo lo usa para preguntas técnicas. Su problema principal es la fragmentación: tiene 7 apps para gestionar su vida y se le escapan cosas. Olvida pagar la mitad del internet, pierde recordatorios de reuniones y nunca sabe cuánto gastó en cafés este mes.

Koru para Martín sería: 'Anota 1500 de cafe' → gasto guardado. 'Cuánto gasté esta semana?' → resumen automático. 'Recuérdame que tengo review el viernes' → recordatorio. 'Cómo le fue a Boca?' → resultado instantáneo. Martín valoraría la unificación: una sola app que reemplaza a 7. Su willingness to pay: USD 8-12/mes.

10.2 Persona 2: Carolina, 38, Gerente de Marketing

Carolina vive en Madrid, tiene dos hijos (8 y 12 años) y trabaja como gerente de marketing en una empresa de tecnología. Gana EUR 55.000/año. Usa Outlook para el calendario laboral, WhatsApp para coordinar con su pareja, y una libreta física para apuntar cosas de los niños (citas médicas, actividades, cumpleaños). Su problema principal es la carga mental: tiene que recordar TODO — la cita del dentista de su hijo, la reunión del martes, que tiene que comprar regalo para el cumple de Sofía, que el coche necesita ITV. Su pareja no ayuda con la organización.

Koru para Carolina sería: el 'segundo cerebro' que la libera de recordar. 'Recuérdame que Leo tiene dentista el 15 a las 16h' → recordatorio guardado. 'Anota: comprar regalo para Sofía' → pendiente. 'Qué tengo esta semana?' → resumen de pendientes. 'Cuánto gastamos en supermercado este mes?' → análisis de gastos. Carolina valoraría la proactividad: que Koru le avise, no que ella tenga que acordarse de preguntar. Su willingness to pay: USD 15-25/mes.

10.3 Persona 3: Roberto, 52, Contador

Roberto vive en Barcelona, es contador autónomo y tiene su propio estudio. Gana EUR 40.000/año. Usa Excel para todo (clientes, facturas, agenda) y tiene un Android que apenas sabe usar más allá de WhatsApp y llamadas. Su hija le instaló

Siri pero solo la usa para hacer llamadas. Su problema principal es que siente que se queda atrás tecnológicamente: ve a sus colegas usar apps de IA pero le parecen demasiado complicadas. Quiere algo simple que le ahorre tiempo sin tener que aprender una interfaz nueva.

Koru para Roberto sería: su secretario digital. Solo tiene que hablarle o escribirle como a una persona. 'Qué tiempo hace mañana?' → clima. 'Anota: reunión con cliente García jueves 10am' → recordatorio. 'Busca las últimas noticias fiscales' → búsqueda. Roberto valoraría la simplicidad: cero curva de aprendizaje, cero menús, solo conversación. Su willingness to pay: USD 10-15/mes, pero necesitaría un plan anual para justificar el gasto.

10.4 Persona 4: Ana, 58, Maestra Jubilada

Ana vive en Sevilla, es viuda y está jubilada. Sus hijos viven en otras ciudades. Usa el móvil para WhatsApp, Facebook y llamadas. Tiene un iPad que le regalaron pero apenas lo usa. Su problema principal es la soledad y el olvido: vive sola, no tiene con quién consultar cosas cotidianas ('¿llueve mañana?', '¿a qué hora juega España?'), y empieza a olvidar cosas (medicamentos, citas médicas). Sus hijos le instalaron Alexa pero no confía en ella porque 'no entiende lo que pregunto'.

Koru para Ana sería: compañía y ayuda. 'Hola Koru' → 'Hola Ana, ¿cómo estás?'. '¿Mañana llueve?' → clima. '¿Cómo le fue a España?' → resultado. 'Recuérdame tomar la pastilla a las 8' → recordatorio. Ana valoraría la personalidad: que Koru la llame por su nombre, que recuerde que tiene hijos en Madrid y Barcelona, que le pregunte cómo está. Su willingness to pay: USD 5-8/mes (fijo). Sus hijos podrían pagar por ella.

11. Análisis Técnico Comparativo

Este capítulo analiza la arquitectura técnica de los principales competidores y cómo se compara con la de Koru. Entender las decisiones técnicas es crucial para evaluar la sostenibilidad de la ventaja competitiva.

11.1 Arquitectura de Modelos

La elección del modelo de lenguaje subyacente es la decisión técnica más importante para un asistente personal. Los competidores usan diferentes enfoques:

App	Modelo subyacente	Self-hosted?	Multi-modelo?	Latencia típica
ChatGPT	GPT-4o / GPT-4o mini	No (OpenAI API)	Sí (2 tiers)	3-15s
Claude	Claude 3.5 Sonnet	No (Anthropic API)	Sí (2 tiers)	5-20s
Gemini	Gemini Pro / Flash	No (Google API)	Sí (2 tiers)	3-10s
Replika	GPT-3.5 / GPT-4 (fine-tuned)	No (OpenAI API)	No	5-15s
Siri	On-device + Apple Cloud	Parcial	No	1-3s
Motion	Propietario (scheduling algo)	Sí	No	1-5s (no LLM)
Koru	NVIDIA Nemotron Ultra + Flash	No (NVIDIA API)	Sí (2 tiers)	2-25s

La arquitectura de Koru es única en varios aspectos: (1) usa NVIDIA Nemotron como modelo principal, lo que evita dependencia de OpenAI/Google; (2) implementa un Model Router de 2 tiers que usa Flash para triviales y Ultra para complejos, optimizando costos y latencia; (3) tiene un Semantic Router basado en embeddings que clasifica la intención en menos de 600ms, permitiendo autofire de tools sin necesidad de una llamada al LLM; y (4) toda la memoria se almacena localmente (IndexedDB), no en la nube, lo que es una ventaja de privacidad significativa.

11.2 Sistema de Memoria

La memoria es el diferenciador técnico más importante de Koru. Veamos cómo se compara:

Feature de memoria	Koru	ChatGPT	Replika	Notion AI
Memoria persistente entre sesiones	Sí (IndexedDB)	Sí (Memory)	Parcial	Sí (en notas)
Memoria confirmable por usuario	Sí (3 estados)	No (opaca)	No	No
Búsqueda semántica en memoria	Sí (embeddings)	Parcial	No	Sí (en notas)
Extracción automática de memoria	Sí (LLM extractor)	Parcial	No	No
Edición/borrado de memorias	Sí (pantalla visual)	Limitada	No	Sí (editar notas)
Local-first (sin nube)	Sí	No (nube OpenAI)	No (nube Luka)	No (nube Notion)

11.3 Latencia y Optimización

La latencia es un factor crítico de UX. Un asistente que tarda 30s en responder no se siente como un asistente, se siente como un buscador lento. Koru ha implementado varias optimizaciones:

- Fast path para inputs triviales (hola, gracias, chau): 2s en lugar de 30s, saltando el Semantic Router y el memory extractor.
- Flash model para síntesis de respuestas: 5-8s en lugar de 15-20s, usando StepFun Flash en lugar de Nemotron Ultra.
- Semantic Router con autofire: cuando el router detecta intención con confianza mayor a 0.78, ejecuta la tool directamente sin esperar al LLM.
- Memory extractor condicional: solo corre para inputs no triviales, ahorrando 5-10s en saludos.
- ESPN API optimizada: 8 ligas en lugar de 15, 2 fechas en lugar de 3, timeout de 6s en lugar de 8s.

Con estas optimizaciones, los tiempos de respuesta actuales son: 2s para triviales, 10-15s para conversación normal, 20-25s para tareas con tools (clima, deportes), y 60-90s para informes de investigación. El objetivo debe ser reducir todos estos tiempos en un 30-50% en los próximos 3 meses.

12. Estrategia Go-to-Market

12.1 Posicionamiento

El posicionamiento de Koru debe ser radicalmente diferente al de sus competidores. No competir con ChatGPT en inteligencia ni con Siri en integración. Competir en la dimensión que ninguna de estas apps ofrece: la relación personal. El messaging debe ser:

- 'No es un chatbot. Es tu secretario que te conoce.' — Diferenciación vs ChatGPT/Claude
- 'No solo te escucha. Te ayuda, te recuerda y te acompaña.' — Diferenciación vs Siri/Alexa
- 'No solo te acompaña. Hace cosas por vos.' — Diferenciación vs Replika/Pi
- 'No necesitas aprender a usarlo. Solo habla.' — Diferenciación vs Motion/Notion

12.2 Canal de Adquisición

La adquisición inicial debe basarse en tres canales:

1. TikTok/Instagram Reels (orgánico): Videos cortos mostrando conversaciones reales con Koru. Ejemplo: 'Le dije a mi asistente que me gusta el café y ahora me recomienda cafeterías'. El contenido viral natural de la IA conversacional es alto, y la personalidad de Koru se presta a momentos compartibles. Costo estimado: USD 0 (orgánico).
2. Product Hunt launch: Un lanzamiento coordinado en Product Hunt con un demo video de 60s mostrando el onboarding conversacional, la memoria confirmable y el wheel. Este canal es ideal para early adopters de 20-35 años. Costo estimado: USD 500 (diseño + video).
3. Referral program: Cada usuario Plus recibe 1 mes gratis por cada amigo que se registre. El referral debe ser fácil: 'Decile a tu amigo que abra este link' o 'Compartí esta conversación con Koru'. El contenido compartible (la personalidad de Koru) es el mejor marketing. Costo estimado: USD 12 por adquisición (1 mes gratis).

12.3 Timing de Lanzamiento

El mercado está en un momento óptimo para lanzar un asistente personal con IA:

- ChatGPT ha educado al mercado (500M+ usuarios saben qué es un chatbot de IA)

- Los usuarios están frustrados con las limitaciones de Siri/Google Assistant (77% no los consideran 'muy útiles')
- Replika ha demostrado que los usuarios desarrollan vínculos con IA (30M+ usuarios)
- La tecnología (LLMs, embeddings, tools) está madura y accesible (NVIDIA API, OpenAI API)
- No hay un competidor que combine utilidad + personalidad + memoria + diseño sin fricción

La ventana de oportunidad es ahora. En 12-18 meses, es probable que OpenAI lance un 'ChatGPT Personal Assistant' con memoria mejorada, o que Apple lance 'Siri Pro' con LLM. Koru debe establecer su posición antes de que los gigantes muevan su atención al segmento de asistentes personales con memoria.

13. Lecciones Aprendidas de Competidores

13.1 Lecciones de Replika

Replika enseña que el vínculo emocional es real y poderoso. Los usuarios de Replika pasan en promedio 2 horas diarias conversando con su IA. Cuando Luka Inc. modificó las capacidades de Replika en 2023 (eliminando rol-play romántico), miles de usuarios reportaron sentimientos de pérdida reales, comparándolo con una ruptura. Un estudio de Harvard Business School documentó este fenómeno como 'discontinuidad de identidad'.

La lección para Koru: la personalidad NO debe cambiar. Una vez que el usuario se acostumbra al tono de Koru, cualquier cambio (más formal, más casual, más servil) será percibido como una traición. La consistencia de personalidad es un feature, no un detalle.

13.2 Lecciones de Pi/Inflection

Pi enseña que la calidad conversacional importa más que las features. Pi no tenía tools, no tenía memoria persistente, no tenía cards visuales. Pero los usuarios lo amaban porque conversaba mejor que cualquier otra IA. Cuando Inflection fue desmantelada, los usuarios lloraron literalmente en redes sociales.

La lección para Koru: el LLM subyacente debe ser el mejor disponible. Si NVIDIA Nemotron no es suficiente, considerar cambiar a Claude o GPT-4o para la conversación principal. La calidad de la conversación es el piso, no el techo.

13.3 Lecciones de Motion

Motion enseña que los usuarios están dispuestos a pagar USD 34/mes por un asistente que hace UNA cosa muy bien (gestionar calendario). Esto sugiere que un asistente que hace MUCHAS cosas bien (clima, gastos, deportes, búsquedas, memoria, recordatorios) puede justificar un precio similar o mayor.

La lección para Koru: el pricing no debe ser tímido. USD 12-25/mes es razonable para un asistente personal integral. El free tier debe ser lo suficientemente bueno para enganchar, pero no tan generoso que no haya incentivo a pagar.

13.4 Lecciones de ChatGPT

ChatGPT enseña que la simplicidad de interfaz gana. A pesar de no tener memoria persistente, no tener personalidad, y no tener tools integradas, ChatGPT tiene 500M+ usuarios porque es simple: una caja de texto y una respuesta. Cualquier

complejidad adicional que Koru agregue debe justificarse con valor claro.

La lección para Koru: el chat es la interfaz. Todo lo demás (wheel, cards, memoria) son capas que no deben interferir con la simplicidad del chat. Si en algún momento el usuario siente que la app es compleja, se pierde el valor principal.

13.5 Lecciones de Notion

Notion enseña que el lock-in de datos es poderoso. Los usuarios de Notion no se van a otra app porque toda su vida está en Notion. Koru debe crear el mismo lock-in: cuantas más memorias tenga el usuario, más difícil será irse. La memoria es el stickiness.

14. Apéndice: Tablas Comparativas Detalladas

14.1 Comparativa de Features

Feature	Koru	ChatGP T	Siri	Replika	Motion	Notion AI
Conversación natural	Sí	Sí	Limitada	Sí	No	Parcial
Memoria persistente	Sí (3 estados)	Parcial	No	Parcial	No	Sí (notas)
Tools reales (clima, etc.)	120+	No	Limitadas	No	No	No
Personalidad definida	Sí	No	Mínima	Sí	No	No
Onboarding conversacional	Sí	No	No	No	No	No
Cards visuales unificadas	Sí (Stitch)	No	Parcial	No	Sí (propias)	No
Wheel navigation	Sí	No	No	No	No	No
Suggestion pills	Sí	No	No	No	No	No
Model Router (Flash/Ultra)	Sí	Sí	No	No	N/A	No
Semantic Router	Sí	No	No	No	No	No
Local-first (IndexedDB)	Sí	No	Parcial	No	No	No
Proactivo (notificaciones)	Próximamente	No	No	No	No	No
App nativa	No (web)	Sí	Sí (built-in)	Sí	Sí	Sí
Calendario integrado	No	No	Sí	No	Sí	No
Email integrado	No	No	No	No	No	No
Notificaciones push	No	Sí	Sí	Sí	Sí	Sí

Feature	Koru	ChatGP T	Siri	Replika	Motion	Notion AI
Multi-idioma	Español	50+	30+	10+	Inglés	10+
Precio free tier	TBD	Sí	Gratis	Sí	No	Sí
Precio premium	TBD	\$20/me s	Gratis	\$20/me s	\$34/me s	\$10/me s

14.2 Comparativa de UX

Aspecto UX	Koru	ChatGPT	Siri	Replika	Motion
Onboarding (tiempo a primer valor)	<30s	10s	0s (built-in)	3min	10min
Interfaz primaria	Chat	Chat	Voz	Chat	Calendario
Carga cognitiva	Mínima	Baja	Mínima	Baja	Alta
Feedback durante espera	WorkingPanel + chips	Cursor	Sonido	Escribiendo...	Spinner
Confirmación de acciones	Card visual	Texto	Voz	Texto	Toast
Gestión de memoria	Pantalla visual	Comando /memory	N/A	Limitada	N/A
Navegación	Wheel long-press	Sidebar	Home screen	Tabs	Menús complejos
Accesibilidad (50-60 años)	Alta (con mejoras)	Media	Alta	Alta	Baja
Retención D30 (estimada)	40% (objetivo)	25%	N/A (built-in)	35%	15%

14.3 Fuentes de Investigación

- Market Research Future — Intelligent Personal Assistant Market Report 2025-2035
- Zion Market Research — Smart Virtual Personal Assistants Market 2024-2034

- Harvard Business School — 'Lessons From an App Update at Replika AI' (2024)
- Pew Research Center — Adoption of AI assistants by age demographic (2024)
- Statista — Voice assistant usage statistics (2024)
- Appsflyer — Mobile app retention benchmarks (2024)
- Nielsen Norman Group — UX for older adults (2023)
- Goodday.work — Best AI personal assistant apps review (2025)
- Morgen.so — 10 Best AI Planning Assistants comparison (2025)
- Saner.ai blog — 20 AI Personal Assistants tested (2025)
- DigitalHumanCorp — AI Companion Apps comparison (2025)
- Cybernews — Best AI apps for iPhone (2025)
- Slack blog — 10 Best AI Tools for Time Management (2024)
- BeyondTime.ai — 10 Best AI Productivity Tools (2025)

— Fin del Informe —